

Sistema Inteligente de Soporte a Decisiones (DSS) para la caracterización multimodal y remediación de zonas mineras mediante segmentación semántica U-Net y lógica difusa.

Washington Andres Apolo Escobar (washington.apolo@unl.edu.ec)

Índice

1. Línea y sublínea de investigación	3
2. Título	3
3. Propósito del proyecto y objetivos	3
3.1. Objetivo General	3
3.2. Objetivos Específicos	4
4. Resultados esperados	4
4.1. Entregables Principales	4
4.2. Estructura de la Memoria del Proyecto	4
4.3. Modelos y Algoritmos a Desarrollar	5
4.4. Relación de Programas	5
5. Palabras Clave	6
6. Introducción y Contexto	6
7. Investigaciones Relacionadas	6
8. Tipo de proyecto	7
9. Preguntas de investigación e hipótesis	8
10. Métodos	8
11. Recursos Requeridos	9
12. Plan de proyecto	9

13. Anexos	12
13.1. Análisis de Viabilidad	12
13.1.1. Viabilidad Técnica	12
13.1.2. Viabilidad Económica	12
13.1.3. Viabilidad Operativa	12
13.2. Análisis y Gestión de Riesgos	12
13.3. Situación actual y situación deseada	12
13.4. Reporte técnico	13
13.5. Declaración del uso de Inteligencia Artificial	13

1. Línea y sublínea de investigación

Línea de Investigación: Tecnologías de la Computación para la Innovación Tecnológica, Desarrollo Sostenible y la Transformación Digital. **Itinerario:** Sistemas Inteligentes.

- *Específicamente:* Sublínea 1.1 Inteligencia Artificial y Aprendizaje Automático – Investiga algoritmos y modelos de AI/ML (redes neuronales, aprendizaje profundo, aprendizaje automático tradicional, inteligencia artificial generativa, modelos grandes de lenguaje) aplicados a problemas como reconocimiento de patrones, predicción, toma de decisiones automatizadas y sistemas adaptativos. Incluye también técnicas de minería de datos para descubrimiento de conocimiento y apoyo a la toma de decisiones inteligentes a partir de grandes volúmenes de información.

Esta propuesta se alinea con el objetivo de aplicar tecnologías emergentes para resolver problemas socioambientales reales de la Zona 7, contribuyendo directamente a los Objetivos de Desarrollo Sostenible (ODS 9, 11 y 15).

2. Título

Sistema Inteligente de Soporte a Decisiones (DSS) para la caracterización multimodal y remediación de zonas mineras mediante segmentación semántica U-Net y lógica difusa.

3. Propósito del proyecto y objetivos

La motivación central de esta investigación reside en mitigar las deficiencias operativas de los métodos actuales de fiscalización minera en la provincia de Zamora Chinchipe, los cuales se caracterizan por una alta latencia y subjetividad humana. El propósito es validar la viabilidad técnica de un prototipo de software que automatice la interpretación de datos geoespaciales. Al integrar visión artificial para la detección y lógica difusa para la evaluación, se busca dotar a las entidades reguladoras de una herramienta objetiva que transforme píxeles satelitales en métricas de riesgo técnico, facilitando una priorización de intervenciones basada en datos cuantificables y no meramente cualitativos.

3.1. Objetivo General

Desarrollar un prototipo de Sistema Inteligente de Soporte a Decisiones (DSS) que integre segmentación semántica (arquitectura U-Net) y lógica difusa para la caracterización

automatizada y la jerarquización de pasivos ambientales por minería ilegal en la provincia de Zamora Chinchipe.

3.2. Objetivos Específicos

- Implementar un modelo de segmentación semántica basado en la arquitectura U-Net, alimentado por datos multimodales (Sentinel-2 y DEM), para la delimitación de socavones y cuerpos de agua turbios, alcanzando un F1-Score superior al 80 % en la extracción de métricas físicas de degradación.
- Determinar el Índice de Impacto Técnico (IIT) de las zonas afectadas mediante un motor de inferencia de lógica difusa que procese la incertidumbre de las variables ambientales, validando la asignación automática de protocolos de remediación frente a criterios expertos.

4. Resultados esperados

4.1. Entregables Principales

Como resultado de la ejecución del proyecto, se generarán los siguientes productos tangibles:

1. **Prototipo de Software DSS:** Una aplicación funcional (backend en Python/TensorFlow) capaz de ingerir coordenadas geográficas, procesar imágenes satelitales y emitir un reporte de riesgo ambiental automatizado.
2. **Dataset Geoespacial Etiquetado:** Un conjunto de datos depurado y validado de la región de Zamora Chinchipe, conteniendo pares de imágenes Sentinel-2 y máscaras binarias de segmentación (Ground Truth), enriquecido con índices espectrales (NDVI, MNDWI).
3. **Modelo U-Net Entrenado:** Los pesos y la arquitectura del modelo de red neuronal optimizado para la detección de morfologías mineras en selva alta, validado mediante métricas de rendimiento.

4.2. Estructura de la Memoria del Proyecto

La memoria técnica se organizará en los siguientes capítulos:

- **Capítulo 1: Introducción.** Contextualización de la minería ilegal en la Amazonía, planteamiento del problema de monitoreo y justificación tecnológica.
- **Capítulo 2: Estado del Arte.** Revisión sistemática sobre teledetección aplicada, arquitecturas CNN para segmentación (U-Net, ResNet) y sistemas de lógica difusa en gestión ambiental.
- **Capítulo 3: Metodología y Materiales.** Descripción del pipeline de procesamiento, construcción del dataset, diseño de la red neuronal y reglas del sistema difuso.
- **Capítulo 4: Desarrollo e Implementación.** Detalles de ingeniería del software, entrenamiento del modelo y construcción del motor de inferencia.
- **Capítulo 5: Resultados y Discusión.** Análisis cuantitativo de métricas (IoU, Precisión), visualización de mapas de calor y validación del IIT contra juicio experto.
- **Capítulo 6: Conclusiones y Recomendaciones.** Síntesis de hallazgos y líneas futuras de investigación.

4.3. Modelos y Algoritmos a Desarrollar

- **U-Net con Backbone ResNet34:** Arquitectura de segmentación semántica elegida por su alto rendimiento con datasets limitados.
- **Algoritmo de Fusión Multimodal:** Procedimiento para integrar datos espectrales (Sentinel-2) con topográficos (DEM).
- **Sistema de Inferencia Difusa (Mamdani):** Algoritmo de toma de decisiones para calcular el Índice de Impacto Técnico.

4.4. Relación de Programas

- **Google Earth Engine (GEE):** Para adquisición y preprocesamiento en la nube.
- **Python (TensorFlow/Keras):** Lenguaje núcleo para el desarrollo del modelo de IA.
- **Scikit-Fuzzy:** Biblioteca para la implementación de la lógica difusa.
- **QGIS:** Para la generación de etiquetas (Ground Truth) y visualización espacial.

5. Palabras Clave

Sistemas de Soporte a Decisiones (DSS), Minería Ilegal, Segmentación Semántica, U-Net, Lógica Difusa, Teledetección, Aprendizaje Profundo.

6. Introducción y Contexto

La provincia de Zamora Chinchipe enfrenta un desafío crítico debido a la expansión de la minería ilegal, actividad que altera drásticamente la cobertura vegetal y la hidrología de las cuencas de los ríos Zamora y Nangaritza. Los métodos tradicionales de fiscalización, basados en patrullajes físicos o denuncias, resultan insuficientes ante la vastedad y difícil acceso del terreno amazónico, generando una respuesta reactiva y tardía por parte de las autoridades.

En este contexto, la presente propuesta plantea un cambio de paradigma hacia la vigilancia digital automatizada. Se propone el uso de imágenes satelitales de acceso abierto (Sentinel-2) combinadas con técnicas avanzadas de Inteligencia Artificial. A diferencia de los enfoques de teledetección clásica que dependen de umbrales manuales, este proyecto implementa redes neuronales profundas capaces de aprender las características morfológicas complejas de los pasivos ambientales, integrando posteriormente un razonamiento experto mediante lógica difusa para cualificar la gravedad del daño sin intervención humana directa.

7. Investigaciones Relacionadas

La Tabla 1 resume los trabajos más relevantes que fundamentan la viabilidad técnica de la propuesta, destacando la evolución desde clasificadores simples hacia arquitecturas profundas y multimodales.

Tabla 1: Síntesis de investigaciones sobre IA y teledetección en minería

Autor(es) y Año	Enfoque y Tecnología	Hallazgos relevantes y relación con el proyecto
Balaniuk [1]	Uso de FCN (Fully Convolutional Networks) para detección y clasificación de riesgo en presas de relaves.	Lograron una precisión del 90.42 % en la clasificación del nivel de impacto (alto vs bajo). Este estudio valida conceptualmente que las redes neuronales pueden ir más allá de la detección, categorizando el riesgo ambiental, premisa central de nuestro DSS.
Boaro [2]	Segmentación de áreas de exploración de oro en la Amazonía usando U-Net con backbone ResNet34.	Alcanzaron una exactitud del 98.34 % y un F1-Score de 76.60 %. Su éxito demuestra que la arquitectura U-Net es superior para delimitar morfologías irregulares en entornos de selva tropical, justificando su elección para nuestro proyecto.
Corone [3]	Detección de cambios en la Amazonía ecuatoriana mediante arquitecturas BAN y ResNet152V2.	Validaron el uso de Deep Learning en el contexto geográfico específico de Ecuador, logrando un 89.6 % de precisión. Confirma que los patrones espectrales locales son detectables con modelos profundos.
Dube [4]	Evaluación de minería ribereña usando Random Forest e índices espectrales (NDVI, MNDWI).	Identificaron que el índice MNDWI es crítico para detectar contaminación en agua asociada a minería. Este hallazgo se incorpora en nuestro pipeline de preprocesamiento multimodal.

8. Tipo de proyecto

El presente trabajo se clasifica como un proyecto de **Desarrollo Tecnológico y Experimental**. Es tecnológico porque su fin último es la construcción de un artefacto de software (prototipo DSS) que resuelva un problema práctico; y es experimental porque implica la validación de hipótesis relacionadas con el rendimiento de algoritmos de IA (U-Net) y la precisión de modelos de inferencia difusa en un entorno controlado con datos reales.

9. Preguntas de investigación e hipótesis

Pregunta 1. ¿Cómo influye la fusión de datos espectrales (Sentinel-2) y topográficos (DEM) en la precisión de la segmentación semántica de pasivos ambientales mineros frente al uso exclusivo de datos ópticos?

Pregunta 2. ¿Qué configuración de hiperparámetros en la arquitectura U-Net maximiza el F1-Score para la detección de socavones irregulares y cuerpos de agua turbios en la topografía de Zamora Chinchipe?

Pregunta 3. ¿En qué medida el uso de un motor de inferencia de lógica difusa reduce la incertidumbre y subjetividad en la categorización de la gravedad del impacto ambiental comparado con sistemas de umbrales rígidos?

Hipótesis General: La implementación de un sistema DSS basado en segmentación semántica U-Net y lógica difusa permitirá cuantificar y categorizar los pasivos ambientales con una precisión superior al 85 %, reduciendo significativamente la subjetividad en la priorización de remediación en comparación con los métodos de inspección visual tradicionales.

10. Métodos

La metodología adopta un enfoque cuantitativo y experimental, estructurado en un pipeline de procesamiento de datos:

- Adquisición y Preprocesamiento:** Se descargarán imágenes Sentinel-2 Nivel 2A (con corrección atmosférica BOA) y Modelos Digitales de Elevación (DEM). Se aplicarán técnicas de normalización y *data augmentation* (rotación, espejado) para mitigar la escasez de datos etiquetados.
- Modelado Inteligente (Visión):** Se diseñará y entrenará una red U-Net. Esta red aprenderá a mapear píxeles de entrada a clases semánticas ("Mina", "Agua Turbia", "Vegetación"). La función de pérdida se optimizará para manejar el desbalance de clases típico de la detección de anomalías.
- Fusión y Extracción de Métricas:** Las máscaras resultantes de la segmentación se cruzarán con datos topográficos para estimar áreas (m^2) y proximidad a cauces hídricos.
- Inferencia Difusa (Decisión):** Se implementará un sistema difuso con variables de entrada (Área, Distancia, Turbidez) y conjuntos difusos (Bajo, Medio, Alto). Un conjunto de reglas expertas determinará el Índice de Impacto Técnico final.

11. Recursos Requeridos

Hardware: Se utilizarán servicios de computación en la nube para el entrenamiento de modelos profundos (Google Colab Pro o Kaggle Kernels con aceleración GPU T4/P100), lo que elimina la necesidad de adquirir estaciones de trabajo costosas localmente.

Software: Todo el desarrollo se realizará sobre plataformas de Código Abierto (Open Source): Lenguaje Python, librerías TensorFlow/PyTorch para Deep Learning, QGIS para la gestión de datos geográficos y etiquetado, y Scikit-Fuzzy para la lógica difusa.

Datos: Se utilizarán repositorios de acceso libre: Copernicus Open Access Hub (imágenes Sentinel-2) y USGS EarthExplorer (datos DEM).

12. Plan de proyecto

El proyecto se ejecutará en un periodo de 16 semanas lectivas, distribuidas conforme al siguiente cronograma:

Tabla 2: Planificación de actividades y tareas del proyecto

Actividad / Tarea técnica	Semanas	Duración (sem)	Dependencia	Resultado principal
Fase 1: Ingeniería de Datos y Diseño del Pipeline				
Actividad 1.1 Construcción del Dataset	1–4	4	-	Dataset Etiquetado
Tarea 1.1.1 Adquisición y filtrado de imágenes Sentinel-2	1–2	2	-	Imágenes Crudas
Tarea 1.1.2 Preprocesamiento y Etiquetado Manual (Ground Truth)	3–4	2	1.1.1	Máscaras de Segmentación
Fase 2: Desarrollo del Modelo de Visión (U-Net)				
Actividad 2.1 Implementación y Entrenamiento	5–9	5	1.1	Modelo Entrenado
Tarea 2.1.1 Diseño de arquitectura U-Net y Data Augmentation	5–6	2	1.1.2	Código del Modelo
Tarea 2.1.2 Entrenamiento y Ajuste de Hiperparámetros	7–9	3	2.1.1	Pesos del Modelo (.h5)
Fase 3: Desarrollo del Motor DSS y Lógica Difusa				
Actividad 3.1 Motor de Inferencia	10–12	3	2.1	Módulo DSS

Actividad / Tarea técnica	Semanas	Duración (sem)	Dependencia	Resultado principal
Tarea 3.1.1 Definición de Conjuntos y Reglas Difusas	10	1	-	Base de Conocimiento
Tarea 3.1.2 Integración Pipeline (Visión + Difuso)	11–12	2	2.1.2, 3.1.1	Prototipo Integrado
Fase 4: Validación y Cierre				
Actividad 4.1 Pruebas y Documentación	13–16	4	3.1	Memoria Técnica
Tarea 4.1.1 Validación de métricas (F1, IoU, Matriz Confusión)	13–14	2	3.1.2	Reporte de Resultados
Tarea 4.1.2 Redacción del Informe Final	15–16	2	4.1.1	Documento Final

13. Anexos

13.1. Análisis de Viabilidad

13.1.1. Viabilidad Técnica

El proyecto es técnicamente viable puesto que se cuenta con el conocimiento base en IA y Teledetección (75 % de dominio previo). La complejidad computacional del entrenamiento de la red U-Net se mitiga mediante el uso de técnicas de *Transfer Learning* y entornos de ejecución en la nube (Google Colab Pro), eliminando la barrera de hardware local.

13.1.2. Viabilidad Económica

El costo financiero es mínimo. Las fuentes de datos (Sentinel-2) son gratuitas bajo la licencia Copernicus. El software utilizado es Open Source. El presupuesto estimado se limita a costos operativos básicos (internet, servicios de nube opcionales) cubiertos por el estudiante (aprox. \$30 USD/mes), lo cual es sostenible.

13.1.3. Viabilidad Operativa

La operatividad está garantizada al no depender de trabajo de campo físico, el cual suele ser costoso y logísticamente complejo en zonas mineras. La validación se realizará mediante "Ground Truth" visual sobre imágenes satelitales de alta resolución históricas, permitiendo cumplir los plazos académicos sin riesgos de seguridad física.

13.2. Análisis y Gestión de Riesgos

- **Riesgo 1 (Nubosidad):** La Amazonía presenta alta cobertura nubosa. *Mitigación:* Uso de mosaicos mensuales libres de nubes y filtros de calidad de píxel (banda QA60).
- **Riesgo 2 (Sobreajuste/Overfitting):** Escasez de imágenes con minería ilegal confirmada. *Mitigación:* Aplicación agresiva de aumento de datos sintético (rotaciones, cambios de iluminación) y regularización (Dropout).

13.3. Situación actual y situación deseada

[Enlace al mapa de la situación actual y la situación deseada](#)

13.4. Reporte técnico

[Enlace al reporte técnico](#)

13.5. Declaración del uso de Inteligencia Artificial

Yo, Washington Andres Apolo Escobar, declaro que en la elaboración del presente trabajo he utilizado herramientas de inteligencia artificial generativa como apoyo instrumental para la estructuración de ideas y la síntesis de literatura técnica. Hago constar que dicho uso se realizó bajo mi estricta supervisión y revisión, asumiendo plena responsabilidad por la veracidad de los datos técnicos, la interpretación de los algoritmos seleccionados y el rigor científico del proyecto.

Referencias Bibliográficas

- [1] Balaniuk, R., Isupova, O., & Reece, S. (2020). Mining and Tailings Dam Detection in Satellite Imagery Using Deep Learning. *Sensors*, 20(23), 6936.
- [2] Boaro, J. M. C., dos Santos, P. T. C., Serra, A., Rego, V. G., Martins, C. V., & Braz Júnior, G. (2021). Satellite Image Segmentation of Gold Exploration Areas in the Amazon Rainforest Using U-Net. In *2021 IEEE International Humanitarian Technology Conference (IHTC)* (pp. 1–8). IEEE.
- [3] Coronel, H., Juela, K., Saquicela, V., Aubet, N., & Lupercio, L. (2024). Artificial Intelligence to the rescue of the Ecuadorian Amazon: Monitoring changes with Deep Learning. Universidad de Cuenca & Universidad Tecnológica del Uruguay.
- [4] Dube, T., Dube, T., Dalu, T., Gxokwe, S., & Marambanyika, T. (2024). Assessment of land use and land cover, water nutrient and metal concentration related to illegal mining activities in an Austral semi-arid river system: A remote sensing and multivariate analysis approach. *Science of the Total Environment*, 907, 167919.